

1 从信息可信到模型可更新：生成式人工智能环境下认知校准的动态框架

作者：张楷明

身份：独立研究者

稿件类型：理论框架与研究议程论文

投稿版本：PSSXiv 投稿定稿，2026 年 9 月

1.1 摘要

生成式人工智能降低了信息检索、解释与表达的成本，但信息可得性的增加并不必然提高认知可靠性。本文研究的问题是：在生成式人工智能参与日常认知活动后，主体如何保持证据、预测、现实反馈与内部模型之间的持续校准。本文提出“模型可更新性”这一工作性构念，指主体在反例、新证据或现实结果与当前模型发生系统性偏差时，能够降低、修改、替换或拒绝原模型，并使后续预测、判断或行动发生可追踪变化的能力。模型可更新性不同于单次判断正确率，也不同于一般的元认知、信念更新、认知灵活性或人机适当依赖：它强调跨轮次的反馈、模型变化和重复错误减少。

本文进一步区分两个正交维度：命题类型包括事实、模型、价值、规范与叙事；证据状态包括支持、反驳和未知。为描述认知主体、信息源、AI、工具、交互和现实约束如何共同影响模型更新，本文采用机学的 $J=(S,M,I,C)$ 作为结构化分析接口，其中 S 表示状态， M 表示模块， I 表示交互， C 表示约束。该四元表示不被本文视为已经验证的认知本体，而被限定为连接命题、证据、预测和反馈的中间表示。

本文构造“现实环境—信息输入—命题形成—类型判断—结构映射—证据—竞争模型—预测—现实反馈—模型更新”的动态闭环，提出反证敏感度、未知保持率、更新幅度、更新速度和重复错误率五类潜在指标，并提出四项可检验命题。进一步设计人独立判断、普通人工智能辅助和结构化人工智能辅助三组动态判断任务，用于检验结构化反馈闭环是否比单纯增加信息更能改善长期认知校准。本文不报告尚未实施的受试者实验结果，也不把机学或模型可更新性表述为已经验证的普适理论。文章的贡献在于将生成式人工智能条件下的认知可靠性，从“第一次是否答对”推进到“面对现实反馈时能否持续更新模型”的动态研究问题，并明确其与信息素养、批判性思维、元认知、认知偏差、适当依赖和系统科学的关系与边界。

关键词： 生成式人工智能；认知校准；模型可更新性；未知状态；人机协同；系统科学

1.2 Abstract

Generative artificial intelligence has reduced the cost of information retrieval, explanation, and expression, but greater information availability does not necessarily produce more reliable cognition. This paper asks how people can maintain calibration among evidence, prediction, real-world feedback, and internal models when generative AI becomes embedded in everyday cognitive activity. It proposes model updatability as a working construct: the capacity of a cognitive system to down-weight, modify, replace, or reject an existing model when counterevidence, new evidence, or observed outcomes systematically diverge from that model, with traceable changes in subsequent predictions, judgments, or actions.

Model updatability is distinguished from one-shot accuracy, general metacognition, belief revision, cognitive flexibility, and appropriate reliance on AI because it emphasizes cross-round feedback, model change, and reductions in repeated error. The paper separates proposition type from evidence status. Proposition types include factual, model-based, value, normative, and narrative propositions;

evidence status includes supported, contradicted, and unknown. Jiology's four-element representation, $J=(S,M,I,C)$, is used as a structured analytical interface: S denotes state, M module, I interaction, and C constraint. It is not presented as an empirically established ontology of cognition.

The paper develops a dynamic loop from real-world environment and information input to proposition formation, type judgment, structural mapping, evidence, competing models, prediction, feedback, and model updating. It proposes five measurable dimensions—counterevidence sensitivity, unknown retention, update magnitude, update latency, and repeated-error rate—and four testable propositions. A three-condition design is proposed: unaided human judgment, ordinary AI assistance, and structured AI assistance with proposition decomposition, competing models, evidence traceability, unknown marking, and outcome review. No unimplemented participant experiment is reported. The contribution is to move the study of cognitive reliability in the generative-AI era from first-answer correctness toward the dynamic question of whether cognitive models can remain open to reality and update over time.

Keywords: generative artificial intelligence; epistemic calibration; model updatability; unknown state; human-AI collaboration; systems science

1.3 一、问题提出：信息更多并不等于认知更可靠

生成式人工智能正在改变认知活动的成本结构。过去，个体需要分别承担检索、筛选、比较、解释和表达的成本；现在，大模型可以在低交互成本下生成摘要、解释、论证、代码和决策建议。认知活动因此不再主要受“能否获得一段文字”限制，而越来越受“能否判断这段文字应当如何进入自己的模型”限制。

这带来一个不同于一般信息可信度判断的问题。主体不仅需要判断某条信息是否来自可靠来源，还需要判断：这条信息描述的是事实、提出的是模型、表达的是价值、规定的是规范，还是组织了一种叙事？当前证据究竟支持它、反驳它，还是仍然不足以判断？它是否应当改变主体对现实的预测？如果预测后来失败，主体是否真的更新了模型，还是只是在语言上承认了错误，却在下一次任务中重复同样的判断？

本文将这一问题概括为**认知校准的动态性**。本文所说的“认知校准”不是一次性判断与标准答案的匹配，而是证据、预测、现实反馈和内部模型之间可以持续连接的过程。生成式 AI 的特殊风险在于，它能够用连贯、完整和自信的语言快速填补证据空白，使“表达流畅”被误认成“证据充分”，也可能使用户在发现错误之后仍然依赖原有叙事。

本文提出的中心研究问题是：

在生成式人工智能参与日常认知活动后，什么样的结构能够使主体在面对反例和现实反馈时持续更新模型，而不是只提高一次性答案的表面正确率？

本文不把机学作为先验结论，也不试图证明一套新的普适认知本体。机学在本文中只承担一个结构化接口的角色，用于连接认知状态、信息与工具模块、主体交互以及限制更新的约束条件。文章的主要理论对象是“模型可更新性”，而不是四元符号本身。

1.4 二、研究定位与相关理论

1.4.1 （一）信息素养：从来源评价到命题进入模型

信息素养研究强调信息的权威性、生产过程、价值、情境和使用方式。ACRL 的高等教育信息素养框架将信息环境视为动态的知识生产与参与过程，而不是简单的“可靠来源清单”[1]。这一传统为生成式 AI 场景提供了重要基础，但本文关注进一步的问题：当命题进入主体的内部模型之后，主体是否根据后续证据、预测和现实结果进行更新？

因此，来源权威不能直接等同于命题真实性。权威可以作为先验或证据权重，但仍需与具体命题、证据边界和现实反馈区分。本文提出的模型可更新性并不取代信息素养，而是试图把信息评价的结果接入一个可追踪的动态过程。

1.4.2 （二）批判性思维、认知偏差与元认知

批判性思维关注理由、证据、推论和论证质量。确认偏误研究表明，主体可能以支持既有信念的方式搜寻、解释和记忆证据[7]；启发式与偏差研究说明，在不确定性条件下，判断会受到可得性、代表性和其他简化机制影响[6]。元认知研究则关注主体对自身认知活动的知识、监控和调节[8]。

本文与这些研究的关系是扩展而非替代。模型可更新性要求主体不仅能够识别自己可能出错，还要在反例出现后改变置信度、模型结构、后续预测或行动。因而，元认知监控可以是模型更新的前置条件，但“知道自己可能有偏差”并不等于“已经降低了错误模型的权重”。

1.4.3 （三）不确定性、理性与信念更新

有限理性研究指出，现实判断受到有限信息、有限计算资源和环境结构的共同影响[4][10]。贝叶斯更新提供了一种形式化描述证据如何改变信念的工具，但现实主体的认知模型还包含类别、关系、目标、资源、制度和行动约束。本文不把真实认知等同于完全贝叶斯理性，而将概率更新视为未来操作化模型可更新性的一个重要参照。

1.4.4 （四）系统科学与人机适当依赖

一般系统论、控制论和系统动力学分别从结构、反馈、通信、调节、状态变量和时间演化等方面研究系统行为[2][3][11]。本文借用其中关于状态、反馈和动态变化的思想，但不主张机学取代这些传统。本文的尝试是提供一个较小的中间表示，使研究者能够同时记录认知状态、工具模块、交互和约束，并将其连接到预测和现实反馈。

生成式 AI 研究还关注自动化偏差、过度依赖和适当依赖。适当依赖的关键不是始终信任或始终拒绝 AI，而是当 AI 正确时依赖、当 AI 错误时拒绝，并使信任程度与实际表现相匹配[14][15]。本文将这一问题推进到跨轮次模型更新：用户是否能在 AI 输出失败后修正自己的模型，而不仅是在当前任务中接受或拒绝一条答案。

1.5 三、核心概念：模型可更新性

1.5.1 （一）工作性定义

本文将**模型可更新性**定义为：当新证据、反例或现实结果与当前模型出现系统性偏差时，认知系统能够降低、修改、替换或拒绝原模型，并使后续预测、判断或行动发生可追踪变化的能力。

该定义包含四个必要条件。第一，系统必须有一个可识别的当前模型，而不是只有无法追踪的直觉或结论。第二，系统必须接收能够与模型比较的证据或反馈。第三，偏差必须能导致模型权重、结构、预测或行动发生变化。第四，这种变化必须能够在后续任务中观察，而不是只出现在事后语言表态中。

模型可更新性不等于模型永远正确。一个模型可以暂时错误, 只要系统能够在反例出现后合理修正; 相反, 一个偶然正确的判断也不等于具有稳定的模型可更新性。本文因此把认知可靠性从静态的“第一次答对”扩展为动态的“面对现实反馈时是否能够持续修正”。

1.5.2 （二）与相邻概念的区别

概念	主要关注点	模型可更新性的新增问题
元认知	主体是否监测和调节自己的认知活动	监测之后是否真的改变模型、预测或行动
信念更新	新证据如何改变信念强度	是否改变模型结构，并减少后续重复错误
认知灵活性	是否能够转换策略或观点	转换是否由现实反馈触发且可追踪
校准	置信度是否与正确率匹配	跨轮次反馈后是否改善未来校准
适当依赖	何时接受或拒绝 AI 输出	AI 失误后主体模型是否更新
学习与迁移	经验是否影响后续任务	更新是否保留、迁移并改变竞争模型权重

模型可更新性不是对这些概念的简单重新命名。本文提出的增量在于把反例、未知、预测、结果和模型版本放入同一条时间链，并将后续错误变化作为重要结果变量。

1.5.3 （三）五个可观察维度

本文提出五个用于未来测量的维度。**反证敏感度**表示反例出现后置信度或模型权重改变的程度；**未知保持率**表示证据不足时主体保留未知而不是强行二值判断的比例；**更新幅度**表示新证据导致模型结构、假设或预测发生的变化；**更新速度**表示从反馈到可观察修正所需的时间或轮次；**重复错误率**表示同类失败在后续任务中再次出现的比例。

五个维度不应被简单加总为一个未经验证的总分。未来需要通过信度、效度和预测效度研究，检验它们是否属于同一构念的不同方面，或实际上对应多个不同能力。

1.6 四、命题类型与证据状态的双层结构

原始认知记录中经常把事实、价值、规范和叙事混写为同一种“真或假”。本文将命题类型和证据状态分为两个正交维度。

1.6.1 （一）命题类型

本文暂时区分五类命题。事实命题描述可由观察或记录检验的状态；模型命题解释多个事实之间的关系并提出机制；价值命题回答“什么值得或什么更好”；规范命题回答“什么应当做”；叙事命题将多个事件组织成具有方向性和意义结构的故事。复杂话语可以同时包含多种类型，因此该分类允许多标签，而不是强迫每句话只属于一类。

1.6.2 (二) 证据状态

证据状态包括**支持、反驳和未知**。支持表示现有证据提高了某命题或模型的可信度；反驳表示证据与其预测或核心假设发生冲突；未知表示证据不足以在当前标准下支持或反驳。未知不是失败答案，而是对证据边界的明确记录。

价值和规范命题不适合简单地按事实真伪判断，但仍然可以记录其理由、前提、利益分布和可接受性。叙事命题也可能具有事实成分和价值方向，因此需要把叙事的组成事实与解释结构分别记录。该双层结构可以避免将“命题是什么”与“证据支持到什么程度”混为一谈。

1.7 五、S/M/I/C：一种结构化分析接口

本文严格使用机学四元结构 $J=(S,M,I,C)$ ，但不把它宣称为已被验证的认知本体。四个元素的操作性含义如下。

状态 s 表示认知主体或人机复合系统在给定时间点的知识、模型、置信度、目标、资源、注意状态和任务状态。

模块 m 表示能够向系统提供信息、转换表示或执行操作的单元，包括记忆、概念、经验、信息源、AI、搜索工具、数据库、他人和组织规则。

交互 i 表示搜索、阅读、提问、对话、争论、核验、行动、工具调用以及现实反馈等过程。交互规定模块之间如何产生状态变化。

约束 c 表示时间、注意力、认知负荷、资源、先验、权限、信息可得性、证据门槛和现实边界。约束决定哪些信息能够进入系统、哪些模型能够被比较以及哪些更新能够实际发生。

在这一表示中，机学的作用是提供一种跨场景中间语言，而不是把认知科学、社会科学或系统科学重新命名。若该表示不能减少结构混乱、提高预测或更新质量，或者不能比现有框架更有效地组织问题，则其理论价值有限。

认知系统的状态变化可以用以下一般形式表示：

$$[s_{t+1} = \Pi_C(s_t + I(M_t))]。$$

该表达式只用于说明状态、模块、交互和约束之间的关系，并不等于已经证明现实认知遵循某一唯一数学规律。模型可更新性还需要进一步使用适合任务的统计或计算更新算子进行操作化。

1.8 六、现实认知的动态闭环

本文提出的核心分析链条是：

现实环境 → 信息或语言输入 → 命题形成 → 命题类型判断 → S/M/I/C 结构识别 → 证据与竞争模型 → 预测 → 现实反馈 → 模型更新 → 新的认知状态。

语言是输入接口，不是证据本身。命题是需要被处理的认知对象；类型判断决定其应采用何种评价方式；结构识别将命题放回主体、模块、交互和约束构成的系统；证据用于缩小可能解释空间；竞争模型要求至少保留一个能够产生不同预测的替代解释；预测把模型暴露给未来；现实反馈决定模型应被保留、降权、修改或删除。

该闭环可以解释几类常见失效。**来源替代命题**将“谁说的”直接转化为“结论为真”；**流畅性替代证据**将表达完整误认成事实支持；**确认偏误闭环**使主体只寻找支持已有模型的信息；**未知坍塌**在证据不足时强迫二值判断；**反馈断裂**则表现为记录观点但不记录预测，或看到结果却不回写模型。

现实反馈也不是天然完美。结果可能有延迟、噪声、混杂变量和不可观测状态。因此，反馈进入模型之前仍需要测量、比较和因果识别。本文提出的闭环并不绕过因果研究，而是为后续因果研究提供状态和记录接口。

1.9 七、人—AI 共同认知系统

AI 不应被置于“现实裁判”位置，而应被置于认知交互模块位置。AI 可以提供候选命题、摘要、反例、竞争模型、检索线索和推演方案，但这些输出仍然是系统内部的一类交互，不等于现实本身。

人—AI 共同认知至少包含两条回路。第一条是语言回路：人提出命题，AI 生成解释或候选模型，人再进行评价。第二条是现实回路：主体根据选择采取行动，现实结果产生反馈，反馈再进入下一轮人—AI 交互。如果系统只有语言回路，就容易形成“语言—语言”的封闭循环；只有现实回路能够使模型暴露于结果约束。

因此，结构化 AI 辅助的最小组件应包括命题拆分、竞争模型、证据回溯、未知标记、预测记录、结果复盘和模型版本化。其目标不是让用户更频繁地相信 AI，而是让人机系统更容易发现错误、保持未知并修正模型。

1.10 八、研究命题与可验证设计

本文提出四项待检验命题。它们不是已经得到验证的经验结论。

P1：模型可更新性与长期判断可靠性相关。在其他条件相近时，能够在反例出现后及时降低错误模型权重的主体，后续重复错误率应低于持续维持原模型的主体。

P2：显式未知机制能够降低无依据确定性。在证据不足的任务中，允许主体保留未知并要求记录证据边界，应降低无依据高置信判断，同时不必然降低对已有证据充分命题的判断准确率。

P3：现实反馈协议比单纯信息补充更能改善长期认知校准。与只提供更多信息相比，要求主体记录预测、结果、误差和模型更新的反馈协议，应更可能改善跨轮次预测校准和重复错误率。

P4：结构化 AI 辅助的效果取决于是否保留认知闭环。带命题拆分、竞争模型、证据回溯、未知标记和结果复盘的 AI 辅助系统，在连续任务中的模型更新质量应优于仅提供答案的 AI 辅助系统。

1.10.1 （一）三组动态判断实验

后续研究可采用随机或准随机实验，将参与者分为三组：A 组独立判断；B 组获得普通 AI 辅助；C 组获得结构化 AI 辅助。三组完成一组具有已知答案、干扰证据、反例和后续反馈的连续判断任务。任务可以覆盖事实核验、因果解释、风险预测或需要跨轮次修正的学习任务。

C 组的最小干预包括五个组件：命题拆分、至少一个竞争模型、证据回溯、未知状态和结果复盘与模型更新。所有组都应记录初始判断、置信度、预测、实际结果和下一轮判断，以便区分一次性正确率与长期更新质量。

1.10.2 （二）主要变量与统计比较

变量类别	指标	解释
首轮表现	判断准确率、置信度	衡量初始任务表现，但不是唯一结果
不确定性	未知保持率、过度自信率	衡量证据不足时的状态管理
反馈响应	反证敏感度、更新幅度、更新速度	衡量模型面对反馈的变化

变量类别	指标	解释
长期表现	预测校准度、重复错误率	衡量跨轮次认知可靠性
过程记录	证据引用、竞争模型数量、模型版本	检验闭环是否真正执行

主要比较应预先规定为跨轮次重复错误率、预测校准度和反证敏感度；首轮准确率作为次要指标。统计分析需要控制任务难度、参与者先验、AI 输出质量和反馈延迟，并报告零结果和干预副作用。模型可更新性不应在实验结果出来后通过任意指标组合定义。

1.11 九、与其他系统科学和认知框架的区别

框架	主要研究对象	本文的关系与差异
信息素养	信息的发现、评价、生产和使用	将信息评价继续连接到模型、预测和现实反馈
批判性思维	论证、证据、推理和判断	增加跨轮次预测、结果和模型更新
元认知	对自身认知活动的监测和调节	区分“知道可能出错”与“实际更新模型”
认知偏差研究	确认偏误、自动化偏差和过度自信等	将偏差视为更新通道可能被阻断的机制，但不取代心理机制解释
贝叶斯与不确定性研究	信念和概率如何根据证据变化	提供更新幅度的形式工具，但不穷尽概念、关系和行动模型
系统动力学	stocks、flows、反馈回路和时间演化	借用动态反馈思想，增加命题—模型—证据的认知记录层
控制论	控制、通信、反馈和调节	关注认知系统是否能根据现实结果调整模型，而非预设目标控制器
多主体或 Agent-Based Modeling	主体、局部规则和群体行为	可作为实现方式，但本文关注认知系统的更新结构
人机适当依赖	何时接受或拒绝 AI 输出	将问题延伸到 AI 失误后的跨轮次模型更新

本文不声称这些比较已经证明模型可更新性是一个独立且优越的理论。比较的真正标准应是：在相同信息条件下，该框架是否能减少结构混乱、提高长期预测或更新质量，并且能够跨任务复用。

1.12 十、理论贡献与边界

本文的理论贡献有三点。第一，将生成式 AI 条件下的认知可靠性从来源可信度和一次性答案正确率推进到模型可更新性。第二，将命题类型与证据状态分开，并把未知作为可持续记录和后续检验的合法状态。第三，将竞争模型、预测、现实反馈和模型更新组织为一个可观察的动态闭环，并以 S/M/I/C 作为结构化接口描述主体、模块、交互和约束。

这些贡献属于理论框架和研究议程层面，不是经验性证明。本文没有证明结构化闭环一定优于普通信息输入，没有证明 S/M/I/C 是认知系统的最小表示，也没有证明“真实认知”在跨文化、跨任务和跨制度环境中具有统一含义。若未来实验不能支持这些命题，相关构念和结构应当被修正。

1.13 十一、讨论：认知可靠性作为过程属性

模型更新并非越快越好。更新过慢可能造成僵化，更新过快则可能追逐噪声。因而，真正的研究对象不是“更新越多越好”，而是更新幅度与证据强度、反馈可靠性和任务后果是否匹配。

认知可靠性也不应被理解为稳定的人格标签。主体在低利益、充足时间和高质量反馈条件下可能能够更新，在高压、强身份认同或资源受限条件下却可能陷入确认偏误。模型可更新性应被视为受到任务、利益、时间、信息结构和关系网络共同影响的状态—结构变量。

“现实认知账本”可以作为未来研究的记录工具。它至少记录命题、命题类型、当前模型、证据、置信度、预测、现实结果和更新动作。它的价值不在于制造更多文档，而在于使“我为什么相信”“我预测了什么”“后来发生了什么”“我是否改变了”能够被追踪和比较。

1.14 十二、局限

第一，模型可更新性的操作化尚未完成统一量表。本文提出的五个维度需要进一步进行信度、效度、测量不变性和预测效度研究。

第二，S/M/I/C 的最小性尚未被数学证明。它目前只是结构化分析接口，需要与已有系统科学、因果模型、认知架构和人机交互模型进行形式比较。

第三，命题类型不是互斥分类。复杂话语可能同时包含事实、价值和叙事层，因此后续研究需要采用多标签或层级标注。

第四，AI 能力变化迅速。不同模型在检索、记忆、工具调用和拒答机制上存在差异，本文不把任何单一模型的表现外推为 AI 的一般属性。

第五，本文没有报告受试者实验或真实行为数据。P1-P4 是待检验命题，实验设计是研究议程而不是已经完成的验证。

1.15 十三、结论

生成式 AI 使信息检索、解释和表达更加容易，但这并不自动提高认知可靠性。本文提出，认知研究需要从“信息是否可信”进一步追问“主体是否能够根据证据、预测和现实反馈持续更新模型”。为此，本文将模型可更新性定义为一种可观察的跨轮次能力，并提出反证敏感度、未知保持率、更新幅度、更新速度和重复错误率五类潜在指标。

本文区分命题类型与证据状态，将事实、模型、价值、规范和叙事与支持、反驳和未知分别处理；使用机学 $J=(S,M,I,C)$ 作为结构化分析接口；构造从现实输入到模型更新的动态闭环；并提出人独立判断、普通 AI 辅助和结构化 AI 辅助三组动态任务设计。

本文的结论是条件性的。文章没有证明模型可更新性已经成为独立成熟理论，也没有证明 S/M/I/C 能够替代既有认知科学或系统科学框架。本文提出的是一个可以被比较、测量、反驳和修正的研究议

程。对于生成式 AI 时代的认知研究而言，真正值得检验的不是系统是否能够持续生成答案，而是它能否在答案与现实不一致时保持未知、识别反例、修正模型并减少下一次重复错误。

1.16 作者声明

本文为理论框架与研究议程论文，不报告尚未实施的受试者实验、现实行为数据或虚构统计结果。文中关于模型可更新性、结构化 AI 辅助和动态认知闭环的内容属于待检验命题或研究设计，不应被解释为已经验证的普适规律。本文不将 AI 置于现实裁判位置，也不将机学表述为已经完成经验验证的认知本体。

1.17 参考文献

- [1] Association of College and Research Libraries. *Framework for Information Literacy for Higher Education*. Chicago: ACRL, 2016. <https://www.ala.org/acrl/standards/ilframework>
- [2] Bertalanffy, L. von. *General System Theory: Foundations, Development, Applications*. New York: George Braziller, 1968.
- [3] Wiener, N. *Cybernetics: Or Control and Communication in the Animal and the Machine*. Cambridge, MA: MIT Press, 1948. <https://mitpress.mit.edu/9780262730099/cybernetics/>
- [4] Simon, H. A. A behavioral model of rational choice. *The Quarterly Journal of Economics*, 1955, 69(1): 99–118. <https://doi.org/10.2307/1884852>
- [5] Popper, K. R. *The Logic of Scientific Discovery*. London: Routledge, 1959.
- [6] Kahneman, D., Slovic, P., & Tversky, A. (eds.). *Judgment under Uncertainty: Heuristics and Biases*. Cambridge: Cambridge University Press, 1982.
- [7] Nickerson, R. S. Confirmation bias: A ubiquitous phenomenon in many guises. *Review of General Psychology*, 1998, 2(2): 175–220. <https://doi.org/10.1037/1089-2680.2.2.175>
- [8] Flavell, J. H. Metacognition and cognitive monitoring: A new area of cognitive-developmental inquiry. *American Psychologist*, 1979, 34(10): 906–911. <https://doi.org/10.1037/0003-066X.34.10.906>
- [9] Stanovich, K. E. *Rationality and the Reflective Mind*. Oxford: Oxford University Press, 2011.
- [10] Gigerenzer, G. *Rationality for Mortals: How People Cope with Uncertainty*. New York: Oxford University Press, 2008.
- [11] Sterman, J. D. *Business Dynamics: Systems Thinking and Modeling for a Complex World*. Boston: McGraw-Hill, 2000.
- [12] Russell, S. *Human Compatible: Artificial Intelligence and the Problem of Control*. New York: Viking, 2019.
- [13] Floridi, L. *The Ethics of Artificial Intelligence: Principles, Challenges, and Opportunities*. Oxford: Oxford University Press, 2023.
- [14] Passi, S., Dhanorkar, S., & Vorvoreanu, M. *Appropriate Reliance on Generative AI: Research Synthesis*. Microsoft Research, 2024. <https://www.microsoft.com/en-us/research/>
- [15] Vorvoreanu, M., Passi, S., Dhanorkar, S., et al. *Fostering Appropriate Reliance on GenAI: Lessons Learned from Early Research*. Microsoft Research, 2025. <https://www.microsoft.com/en-us/research/>
- [16] Singh, A., Guan, Z., & Rieh, S. Y. Enhancing critical thinking in generative AI search with metacognitive prompts. *Proceedings of the Association for Information Science and Technology*, 2025, 62(1): 672–684.
- [17] Raitsaka, L., & Tikhonova, E. Enhancing critical thinking skills in ChatGPT-human interaction: A scoping review. *Journal of Language and Education*, 2025.

[18] 中国人民大学书报资料中心. 哲学社会科学预印本平台常见问题解答. <https://zsyyb.cn/user/problemSolving.htm>